



**Министерство науки и высшего образования Российской
Федерации**
**Федеральное государственное автономное образовательное
учреждение**
высшего образования
**«Московский государственный технический университет
имени Н.Э. Баумана**
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

ОТЧЕТ
ПО ДОМАШНЕМУ ЗАДАНИЮ

По дисциплине «Методы машинного обучения»

«Сравнение функций потерь обучения моделей эмбединга текстов»

Студент ИУ5-21М
(Группа)

(Подпись, дата)

Н.М. Горкунов
(И.О.Фамилия)

Преподаватель

(Подпись, дата)

Ю.Е. Гапанюк
(И.О.Фамилия)

Москва – 2026

Введение

В работе сравниваются функции потерь, применяемые для обучения моделей текстовых эмбеддингов. Цель эксперимента - проверить, как разные функции потерь изменяют качество представлений при одинаковых данных, одинаковом числе обучающих записей и одинаковом количестве обучаемых параметров.

В качестве базовой модели используется sentence-transformers/msmarco-distilbert-base-dot-prod-v3. Transformer encoder и pooling остаются замороженными, а Dense projection head размерности 768x768 переинициализируется перед каждым запуском. Такой режим изолирует влияние функции потерь лучше, чем полное дообучение всех весов модели на малом наборе данных.

Задание

Необходимо подготовить несколько качественных датасетов для разных форматов обучения эмбеддингов, привести их к одинаковому размеру и сравнить Contrastive Loss, Triplet Loss, InfoNCE Loss, NT-Xent Loss, Supervised Contrastive Loss и Circle Loss. Результаты эксперимента фиксируются в Jupyter Notebook и используются для анализа качества функций потерь.

Подготовка данных

Для основного сравнения выбраны четыре англоязычных датасета: all-nli, quora-duplicates, banking77 и twenty-newsgroups. Для каждого применимого представления используется 5000 train-записей и 1000 test-записей. Датасет STS-B используется только как внешняя проверка семантической близости.

Таблица 1 - Нормализованные представления датасетов

dataset_id	view	split	rows
all_nli	contrastive_pair	test	1000
all_nli	contrastive_pair	train	5000
all_nli	positive_pair	test	1000
all_nli	positive_pair	train	5000
all_nli	triplet	test	1000
all_nli	triplet	train	5000
banking77	class_text	test	1000
banking77	class_text	train	5000
banking77	contrastive_pair	test	1000
banking77	contrastive_pair	train	5000
banking77	positive_pair	test	1000
banking77	positive_pair	train	5000
banking77	triplet	test	1000

banking77	triplet	train	5000
quora_duplicates	contrastive_pair	test	1000
quora_duplicates	contrastive_pair	train	5000
quora_duplicates	positive_pair	test	1000
quora_duplicates	positive_pair	train	5000
quora_duplicates	triplet	test	1000
quora_duplicates	triplet	train	5000
stsb_eval	sts_pair	test	1379
stsb_eval	sts_pair	train	5749
twenty_newsgroups	class_text	test	1000
twenty_newsgroups	class_text	train	5000
twenty_newsgroups	contrastive_pair	test	1000
twenty_newsgroups	contrastive_pair	train	5000
twenty_newsgroups	positive_pair	test	1000
twenty_newsgroups	positive_pair	train	5000

Для pair/triplet датасетов class_text представление не строится, так как у них нет устойчивых single-text классов. Поэтому SupCon и Circle Loss сравниваются на banking77 и twenty-newsgroups.

Методика эксперимента

Во всех запусках используется seed = 42, batch_size = 256, epochs = 6, learning_rate = 0.01, weight_decay = 0.0001. Количество обучаемых параметров projection head равно 589824.

Перед обучением для всех текстов кэшируются эмбединги замороженной части модели: DistilBERT encoder и mean pooling. Затем для каждой функции потерь создается новая Linear projection head с Xavier-инициализацией. Именно эта матрица обучается на соответствующем представлении датасета.

Для раннего останова 5000 исходных train-записей детерминированно делятся на 4000 обучающих и 1000 validation-записей. После каждой эпохи вычисляется validation-метрика; если она не улучшается на 0.0001 в течение 2 эпох, обучение останавливается, а веса откатываются к лучшей эпохе. Test-выборка применяется только для финальной оценки.

Таблица 2 - Конфигурация эксперимента

Параметр	Значение
Базовая модель	sentence-transformers/msmarco-distilbert-base-dot-prod-v3
Архитектура	DistilBERT encoder + mean pooling + Dense(768, 768, bias=False)
Режим обучения	Frozen transformer and pooling; Dense

	projection head reinitialized and trained.
Projection dim	768
Temperature	0.05
Contrastive margin	0.4
Triplet margin	0.2
Circle margin / gamma	0.25 / 32.0

Результаты

Основная метрика зависит от формата обучения: для contrastive pair используется ROC-AUC, для triplet - доля триплетов с большей близостью positive, для InfoNCE/NT-Xent - top-1 retrieval, для SupCon/Circle - accuracy 1-NN классификации по эмбедингам.

Таблица 3 - Итоговые метрики по функциям потерь

dataset	loss	metric	value	best epoch	val metric	train metric	val loss	train loss
NLI	contrastive	Pair AUC	0.757	5	0.763	0.954	0.151	0.095
NLI	triplet	Triplet acc.	0.866	2	0.869	0.953	0.065	0.041
NLI	infonce	Top-1	0.769	1	0.753	0.702	0.683	0.789
NLI	nt_xent	Top-1	0.758	1	0.747	0.708	0.772	0.774
Quora	contrastive	Pair AUC	0.877	5	0.851	0.957	0.117	0.072
Quora	triplet	Triplet acc.	0.954	2	0.953	0.999	0.013	0.003
Quora	infonce	Top-1	0.853	1	0.844	0.730	0.416	0.439
Quora	nt_xent	Top-1	0.848	2	0.835	0.742	0.194	0.140
Banking 77	contrastive	Pair AUC	0.972	12	0.974	0.992	0.109	0.076
Banking 77	triplet	Triplet acc.	0.974	4	0.966	1.000	0.019	0.002
Banking 77	infonce	Top-1	0.019	3	0.066	0.011	2.702	2.307
Banking 77	nt_xent	Top-1	0.018	6	0.073	0.015	2.514	2.006
Banking 77	supcon	1-NN acc.	0.879	2	0.878	0.897	2.579	2.486
Banking 77	circle	1-NN acc.	0.903	6	0.880	0.928	16.407	14.050
20News	contrastive	Pair AUC	0.826	9	0.840	0.931	0.246	0.185
20News	triplet	Triplet acc.	0.827	2	0.835	0.954	0.077	0.042
20News	infonce	Top-1	0.005	2	0.014	0.001	4.654	4.509
20News	nt_xent	Top-1	0.002	4	0.009	0.002	4.653	4.197
20News	supcon	1-NN	0.611	2	0.648	0.664	4.497	4.491

		acc.						
20News	circle	1-NN acc.	0.609	7	0.672	0.702	21.390	20.284

Таблица 4 - Baseline без обучения projection head

dataset	view	metric	value
NLI	Pair	Pair AUC	0.695
NLI	Triplet	Triplet acc.	0.805
NLI	Pos. pair	Top-1	0.733
Quora	Pair	Pair AUC	0.82
Quora	Triplet	Triplet acc.	0.952
Quora	Pos. pair	Top-1	0.848
Banking77	Pair	Pair AUC	0.92
Banking77	Triplet	Triplet acc.	0.913
Banking77	Pos. pair	Top-1	0.02
Banking77	Class	1-NN acc.	0.881
20News	Pair	Pair AUC	0.698
20News	Triplet	Triplet acc.	0.728
20News	Pos. pair	Top-1	0.004
20News	Class	1-NN acc.	0.584
STS-B	STS	Spearman	0.786




Рисунок 1 - Основные метрики по датасетам и функциям потерь




Рисунок 2 - Contrastive Loss: train/val loss и целевая метрика по датасетам




Рисунок 3 - Triplet Loss: train/val loss и целевая метрика по датасетам




Рисунок 4 - InfoNCE Loss: train/val loss и целевая метрика по датасетам




Рисунок 5 - NT-Xent Loss: train/val loss и целевая метрика по датасетам




Рисунок 6 - SupCon Loss: train/val loss и целевая метрика по датасетам




Рисунок 7 - Circle Loss: train/val loss и целевая метрика по датасетам

Для all-nli и quora-duplicates наиболее естественными являются pair, triplet и in-batch retrieval постановки. Для banking77 и twenty-newsgroups class-label losses показывают смысловую структуру классов через 1-NN accuracy. Низкие значения retrieval_top1 у InfoNCE/NT-Xent на class-derived positive_pair не означают провал обучения: в этих датасетах у одного класса много равноправных positive-примеров, а метрика требует попасть ровно в пару с тем же индексом.

Выводы

Итоговые графики и таблица метрик показывают, что loss-функции нельзя корректно сравнивать по одной числовой шкале: для разных форматов

данных основными метриками были pair AUC, triplet accuracy, retrieval top-1 и 1-NN accuracy. Поэтому главный вывод не в том, что один loss «лучше» всех, а в том, какая функция потерь соответствует задаче и организации labels.

Contrastive Loss лучше всего интерпретируется как loss для binary pair verification: поиск дубликатов, same/different пары, entailment/contradiction и другие сценарии, где нужен порог схожести. В этом формате он дает сильные test pair AUC: 0.757 на NLI, 0.877 на Quora, 0.972 на Banking77 и 0.826 на 20News. На графиках у него часто виден разрыв между train и val метрикой, поэтому его стоит использовать с early stopping по validation-метрике.

Triplet Loss наиболее нагляден для задач ранжирования и относительной близости, где есть осмысленная тройка anchor-positive-negative. Итоговые графики показывают, что best epoch для него обычно наступает рано, но test triplet accuracy остается высокой: 0.866 на NLI, 0.954 на Quora, 0.974 на Banking77 и 0.827 на 20News. Это делает Triplet Loss сильным выбором для retrieval/ranking-сценариев, но требует качественного способа семплировать negatives.

InfoNCE и NT-Xent подходят для in-batch retrieval, где у anchor есть один целевой positive в батче. На NLI и Quora эти loss дают адекватный test retrieval top-1: для InfoNCE 0.769 и 0.853, для NT-Xent 0.758 и 0.848. На Banking77 и 20News они выглядят плохо именно в exact paired-index метрике: test top-1 снижается до 0.019/0.005 у InfoNCE и 0.018/0.002 у NT-Xent. Это не доказывает непригодность самих loss-функций, а показывает несовпадение loss, разметки и метрики: на class-label данных у одного anchor есть много равноправных positives.

SupCon и Circle Loss стоит брать для class-label данных: intent classification, topic clustering и других сценариев, где нужно сблизить все объекты одного класса. На Banking77 Circle Loss дает лучший class-label test результат: 1-NN accuracy 0.903 против 0.879 у SupCon. На 20News test-разница мала: 0.611 у SupCon и 0.609 у Circle, но на validation-графике Circle выше (0.672 против 0.648). Для сильно размеченных классов по этим графикам Circle выглядит чуть более устойчивым, а SupCon - более простым и близким по качеству вариантом.

Практическая карта выбора по итогам эксперимента такая: для pair verification - Contrastive Loss; для ranking/retrieval с явным negative - Triplet Loss; для in-batch retrieval с одним целевым positive - InfoNCE и NT-Xent; для данных с метками классов - SupCon и Circle Loss. Во всех случаях best epoch

нужно выбирать по целевой validation-метрике: итоговые графики показывают, что train loss может падать дальше без улучшения целевой метрики на validation.

Список использованных источников

1. Hadsell R., Chopra S., LeCun Y. Dimensionality Reduction by Learning an Invariant Mapping. 2006.
2. Hoffer E., Ailon N. Deep Metric Learning using Triplet Network. 2014.
3. van den Oord A., Li Y., Vinyals O. Representation Learning with Contrastive Predictive Coding. 2018.
4. Chen T., Kornblith S., Norouzi M., Hinton G. A Simple Framework for Contrastive Learning of Visual Representations. 2020.
5. Khosla P. et al. Supervised Contrastive Learning. 2020.
6. Sun Y. et al. Circle Loss: A Unified Perspective of Pair Similarity Optimization. 2020.
7. Reimers N., Gurevych I. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. 2019.
8. Hugging Face model card: sentence-transformers/msmarco-distilbert-base-dot-prod-v3.
9. Hugging Face datasets: sentence-transformers/all-nli, sentence-transformers/quora-duplicates, mteb/banking77, SetFit/20_newsgroups, sentence-transformers/stsb.