

Рубежный контроль №1

Горкунов Николай Максимович, ИУ5-21М

Номер варианта	Номер задачи №1	Номер задачи №2
2	2	22

Задание

Для студентов групп ИУ5-21М, ИУ5И-21М необходимо для пары произвольных колонок данных построить график "Диаграмма рассеяния".

Задача №2: для набора данных провести кодирование одного категориального признака с использованием метода "target (mean) encoding".

Датасет

Использован набор данных CO2 Emission by Vehicles. Файл: data/CO2_Emissions_Canada.csv. Размер датасета: 7385 строк и 12 колонок.

Фрагмент исходного датасета

Make	Model	Vehicle Class	Engine Size(L)	Fuel Type	CO2 Emissions(g/km)
ACURA	ILX	COMPACT	2.0	Z	196
ACURA	ILX	COMPACT	2.4	Z	221
ACURA	ILX HYBRID	COMPACT	1.5	Z	136
ACURA	MDX 4WD	SUV - SMALL	3.5	Z	255
ACURA	RDX AWD	SUV - SMALL	3.5	Z	244
ACURA	RLX	MID-SIZE	3.5	Z	230

Проверка пропусков

Были проверены явные пропуски NaN во всех колонках и пустые строки в категориальных признаках. В датасете не обнаружено ни NaN, ни пустых строк, поэтому удаление строк, удаление колонок или заполнение значений не требуется.

Признак	Тип	NaN	NaN, %
Make	str	0	0.0
Model	str	0	0.0
Vehicle Class	str	0	0.0
Engine Size(L)	float64	0	0.0
Cylinders	int64	0	0.0
Transmission	str	0	0.0
Fuel Type	str	0	0.0
Fuel Consumption City (L/100 km)	float64	0	0.0
Fuel Consumption Hwy (L/100 km)	float64	0	0.0
Fuel Consumption Comb (L/100 km)	float64	0	0.0
Fuel Consumption Comb (mpg)	int64	0	0.0
CO2 Emissions(g/km)	int64	0	0.0

Пустые строки в категориальных признаках

Категориальный признак	Пустые строки
Make	0
Model	0
Vehicle Class	0
Transmission	0
Fuel Type	0

Выполнение target / mean encoding

Для кодирования выбран категориальный признак Make. Целевой признак - CO2 Emissions(g/km). Каждое значение Make заменено средним значением целевого признака для соответствующей марки автомобиля. Новый признак: Make_mean_encoded.

Фрагмент таблицы средних значений по категориям

Make	manual_mean	encoded_value	abs_diff
BUGATTI	522.0	522.0	0.0
LAMBORGHINI	400.780487804878	400.780487804878	0.0
SRT	389.0	389.0	0.0
ROLLS-ROYCE	388.48	388.48	0.0
BENTLEY	362.9347826086956	362.9347826086956	0.0
ASTON MARTIN	339.6170212765957	339.6170212765957	0.0
MASERATI	318.1475409836066	318.1475409836066	0.0
GMC	299.9176829268293	299.9176829268293	0.0

Расхождение между ручным расчетом среднего и значением TargetEncoder равно 0.0 для показанных категорий и для всей таблицы проверки.

Фрагмент датасета после кодирования

Make	Model	Engine Size(L)	CO2 Emissions(g/km)	Make_mean_encoded
ACURA	ILX	2.0	196	223.65277777777777
ACURA	ILX	2.4	221	223.65277777777777
ACURA	ILX HYBRID	1.5	136	223.65277777777777
ACURA	MDX 4WD	3.5	255	223.65277777777777
ACURA	RDX AWD	3.5	244	223.65277777777777
ACURA	RLX	3.5	230	223.65277777777777
ACURA	TL	3.5	232	223.65277777777777
ACURA	TL AWD	3.7	255	223.65277777777777

Диаграмма рассеяния

Построена диаграмма рассеяния для колонок Engine Size(L) и CO2 Emissions(g/km). Цвет точек соответствует признаку Fuel Type.

